Documento de Explicação Técnica

Projeto: CP1 - GenAI - SUPER APP DE GENAI

Curso: Inteligência Artificial - FIAP

Professor: Erick Gomes

Integrantes:

RM567638 - Pedro Iavarone Custódio

Introdução

Este documento detalha a implementação de três novas funcionalidades de inteligência artificial ao “SUPER APP DE GENAI” base, construído com a interface Gradio. Todos os modelos selecionados são open-source e executados localmente através da biblioteca transformers (Hugging Face), sem a utilização de requisições a APIs externas.

Funcionalidade 1: Classificação de Imagens

- **Modelo Utilizado:** google/vit-base-patch16-224 (Vision Transformer - ViT).
- **Problema que Resolve:** Visão computacional para reconhecimento de padrões, identificando o objeto principal presente em uma imagem.
- **Entrada e Saída:**
    - Entrada: Uma imagem (arquivo nos formatos JPG, PNG, etc.).
    - Saída: Textos contendo as categorias (rótulos) identificadas e suas respectivas porcentagens de confiança (score).
- **Por que foi escolhido:** O ViT é uma arquitetura moderna que aplica o conceito de Transformers (originalmente usado em textos) diretamente em blocos de pixels (patches), oferecendo uma precisão superior em relação às redes neurais convolucionais (CNNs) tradicionais para muitas tarefas de visão, mantendo um peso computacional viável para testes locais.
- **Principais Limitações:** O modelo foi treinado no dataset ImageNet (1.000 classes predefinidas). Ele não consegue classificar objetos que fujam dessas 1.000 categorias e os rótulos de saída estão estritamente em inglês.
- **Exemplos de Utilização:**
    - **Organização de Galerias:** Categorização automática de fotos em um sistema de armazenamento em nuvem (ex: separar fotos de "carros", "cachorros", "praia").
    - **Inventário de E-commerce:** Uma loja pode fazer o upload de milhares de fotos de produtos e o modelo pré-classifica do que se trata o objeto principal da imagem.

Funcionalidade 2: Transcrição de Áudio (Speech-to-Text)

- **Modelo Utilizado:** openai/whisper-tiny (Whisper).
- **Problema que Resolve:** Reconhecimento Automático de Fala (ASR), convertendo linguagem falada (áudio) em texto escrito.
- **Entrada e Saída:**
    - Entrada: Um arquivo de áudio ou gravação de voz direta pelo microfone.
    - Saída: Uma string de texto contendo a transcrição do que foi dito.
- **Por que foi escolhido:** O Whisper é reconhecido por sua extrema robustez contra ruídos de fundo e diferentes sotaques. Optei pela versão tiny por ser

altamente otimizada, consumindo pouca memória RAM/VRAM, o que garante execuções rápidas e sem travamentos em ambientes locais ou no Colab, sem depender da API paga da OpenAI.

- **Principais Limitações:** A versão tiny, para ser leve, sacrifica uma pequena margem de precisão. Em áudios muito longos, rápidos ou com vocabulário extremamente técnico, o modelo pode apresentar alucinações ou pequenas falhas gramaticais em comparação com a versão Large.
- **Exemplos de Utilização:**
    - **Acessibilidade e Legendas:** Geração de legendas automáticas para vídeos ou palestras gravadas.
    - **Automação de Reuniões:** Profissionais podem gravar reuniões, entrevistas ou áudios do WhatsApp e usar o modelo para converter tudo em texto para gerar atas ou resumos rapidamente.

Funcionalidade 3: Geração de Legendas para Imagens (Image-to-Text)

- **Modelo Utilizado:** Salesforce/blip-image-captioning-base (BLIP).
- **Problema que Resolve:** Compreensão multimodal de cena. Ele não apenas classifica um objeto, mas entende o contexto visual e gera uma frase descritiva sobre o que está acontecendo na imagem.
- **Entrada e Saída:**
    - Entrada: Uma imagem.
    - Saída: Uma frase em formato de texto (string) descrevendo a cena.
- **Por que foi escolhido:** O BLIP (Bootstrapping Language-Image Pre-training) unifica visão computacional e processamento de linguagem natural com alta coerência semântica. É um dos modelos base open-source mais eficientes atualmente para captioning sem exigir hardwares robustos.
- **Principais Limitações:** O modelo gera legendas exclusivamente em inglês. Além disso, pode ser bastante literal, falhando em interpretar contextos subjetivos, artísticos ou sarcásticos presentes na imagem.
- **Exemplos de Utilização:**
    - **Acessibilidade na Web (Alt Text):** Geração automática de textos alternativos (descrições de imagens) para pessoas com deficiência visual que usam leitores de tela em sites.
    - **Redes Sociais e Marketing:** Sugestão automática de descrições para postagens no Instagram ou catálogos de produtos baseada no que está acontecendo na foto.

Disponibilização da Aplicação (Deploy Temporário)

- A interface foi configurada com o parâmetro *“share=True”* na inicialização do Gradio. Isso gera uma URL pública temporária (Hugging Face Spaces/Gradio Live), que permite que o aplicativo seja acessado de qualquer navegador. Todo o processamento continua acontecendo localmente na máquina

hospedeira onde o código está em execução, garantindo a privacidade dos dados e cumprindo a restrição de não consumir APIs em nuvem para o processamento de IA.